

Redes Neurais Convolucionais (CNN)

Dataset RAG — Circuitos & Redes Neurais Artificiais

1. Motivação

Redes Neurais Convolucionais (CNNs) foram projetadas para processar dados com estrutura espacial, como imagens. Redes totalmente conectadas (MLP) não escalam bem para imagens: uma imagem 224x224x3 teria 150.528 entradas, gerando milhões de parâmetros na primeira camada.

2. Operação de Convolução

A convolução aplica um filtro (kernel) sobre a entrada deslizando-o por toda a imagem. Para um kernel K e entrada I , o resultado na posição (i,j) é:

$$(I * K)[i, j] = \sum_m \sum_n I[i+m, j+n] * K[m, n]$$

O kernel aprende a detectar padrões locais: bordas, texturas, formas. Camadas mais profundas detectam padrões mais complexos (olhos, rodas, etc.).

3. Camadas de Pooling

O pooling reduz as dimensões espaciais da feature map, tornando a rede invariante a pequenas translações. O MaxPooling seleciona o valor máximo em cada região:

MaxPool 2x2: pega o maximo em regioes de 2x2 pixels com stride 2

O AveragePooling calcula a média. O Global Average Pooling reduz cada feature map a um único valor, substituindo camadas totalmente conectadas.

4. Arquiteturas Classicas

LeNet-5 (1998): pioneira em reconhecimento de dígitos. 2 conv + 3 FC.

AlexNet (2012): venceu o ImageNet com 15.3% de erro top-5. Introduziu ReLU e dropout.

VGG-16 (2014): 16 camadas com kernels 3x3. Simples e eficaz.

ResNet (2015): introduziu conexões residuais (skip connections), permitindo treinar redes com 100+ camadas sem degradação de gradiente.

EfficientNet (2019): escala largura, profundidade e resolução de forma balanceada.

5. Transfer Learning

Redes pré-treinadas em grandes datasets (ImageNet) podem ser reutilizadas para novos problemas. As camadas convolucionais aprendem features genéricas reutilizáveis. Apenas as últimas camadas são re-treinadas (fine-tuning). Reduz drasticamente a necessidade de dados e tempo de treinamento.