

Redes Recorrentes: RNN, LSTM e GRU

Dataset RAG — Circuitos & Redes Neurais Artificiais

1. Redes Recorrentes (RNN)

RNNs processam sequências mantendo um estado oculto que captura informações anteriores. Para cada passo de tempo t :

$$h_t = \tanh(W_h * h_{(t-1)} + W_x * x_t + b)$$

$$y_t = W_y * h_t + b_y$$

O estado oculto h_t funciona como memória de curto prazo. RNNs são usadas em séries temporais, PLN e reconhecimento de fala.

2. Problema do Gradiente Vanishing

Em sequências longas, o backpropagation through time (BPTT) multiplica gradientes por centenas de passos. Se os pesos são < 1 , os gradientes decaem exponencialmente (vanishing). Se > 1 , explodem (exploding). Isso impede RNNs de capturar dependências de longo prazo.

3. LSTM (Long Short-Term Memory)

Propostas por Hochreiter e Schmidhuber (1997), as LSTMs resolvem o vanishing gradient com um mecanismo de porta (gates) e uma célula de memória separada:

$$\text{Porta de esquecimento: } f_t = \sigma(W_f * [h_{(t-1)}, x_t] + b_f)$$

$$\text{Porta de entrada: } i_t = \sigma(W_i * [h_{(t-1)}, x_t] + b_i)$$

$$\text{Candidato a célula: } \tilde{C}_t = \tanh(W_c * [h_{(t-1)}, x_t] + b_c)$$

$$\text{Célula de memória: } C_t = f_t * C_{(t-1)} + i_t * \tilde{C}_t$$

$$\text{Porta de saída: } o_t = \sigma(W_o * [h_{(t-1)}, x_t] + b_o)$$

$$\text{Estado oculto: } h_t = o_t * \tanh(C_t)$$

4. GRU (Gated Recurrent Unit)

Simplificação da LSTM com apenas duas portas (reset e update), proposta por Cho et al. (2014). Menos parâmetros e treinamento mais rápido com desempenho comparável à LSTM em muitas tarefas.

5. Aplicacoes

- Tradução automática (seq2seq com encoder-decoder)
- Geração de texto e previsão de próxima palavra
- Análise de sentimentos

- Previsao de series temporais financeiras
- Reconhecimento de voz (Wav2Vec, DeepSpeech)