

Transformers e Mecanismo de Atencao

Dataset RAG — Circuitos & Redes Neurais Artificiais

1. Limitacoes das RNNs e Motivacao

Apesar de eficazes, RNNs e LSTMs possuem limitações importantes: processamento sequencial (dificulta paralelização), dificuldade com dependências muito longas e gargalo de informação em arquiteturas encoder-decoder. O artigo 'Attention Is All You Need' (Vaswani et al., 2017) propôs os Transformers como alternativa baseada puramente em atenção.

2. Mecanismo de Atencao (Self-Attention)

A atenção permite que cada posição da sequência 'preste atenção' a todas as outras. Para cada token, são calculados três vetores: Query (Q), Key (K) e Value (V):

$$Q = X * W_Q, K = X * W_K, V = X * W_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}(Q * K^T / \sqrt{d_k}) * V$$

O fator de escala $\sqrt{d_k}$ evita que o produto interno cresça demais. O resultado é uma combinação ponderada dos Values, onde os pesos indicam a relevância de cada posição para a posição atual.

3. Multi-Head Attention

Em vez de calcular atenção uma vez, o Transformer usa h cabeças (heads) em paralelo, cada uma aprendendo diferentes aspectos das relações entre tokens:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) * W_O$$

$$\text{head}_i = \text{Attention}(Q * W_{Qi}, K * W_{Ki}, V * W_{Vi})$$

4. Arquitetura do Transformer

O Transformer original possui encoder e decoder, cada um com N camadas ($N=6$). Cada camada do encoder contém:

1. Multi-Head Self-Attention

2. Feed-Forward Network (2 camadas lineares com ReLU)

3. Layer Normalization e conexoes residuais em cada sub-camada

5. Positional Encoding

Como o Transformer não é recorrente, precisa de informação de posição. O positional encoding é somado ao embedding de cada token:

$$\text{PE}(\text{pos}, 2i) = \sin(\text{pos} / 10000^{(2i/d_{\text{model}})})$$

$$\text{PE}(\text{pos}, 2i+1) = \cos(\text{pos} / 10000^{(2i/d_{\text{model}})})$$

6. Modelos Baseados em Transformers

BERT (2018): pre-treinamento bidirecional com masked language modeling. Excelente para tarefas de compreensão de texto.

GPT (2018-2023): geração autoregressiva. Base do ChatGPT. GPT-4 tem estimados 1 trilhão de parâmetros.

T5 (2019): unifica todas as tarefas de NLP como text-to-text.

Gemma (2024): modelo open-weights do Google, 2B a 27B parâmetros, otimizado para inferência eficiente e uso acadêmico/comercial.